Laboratório 9: Polars

João Vitor Saes Casagrande

```
import polars as pl
pl.Config.set_tbl_formatting("ASCII_MARKDOWN")

basics = pl.read_csv("title.basics0.tsv.gz", separator="\t", null_values=r"\N")
ratings = pl.read_csv("title.ratings.tsv.gz", separator="\t", null_values=r"\N")
principals = pl.read_csv("title.principals0.tsv.gz", separator="\t", null_values=r"\N")

   # 1. Quais são os 5 filmes com as maiores notas (averageRating)?
   # Desempate pelo número de votos recebidos.
q1 = (
    basics.filter(pl.col("titleType") == "movie") # Filtrar apenas filmes
    .join(ratings, on="tconst", how="inner")
    .sort(by=["averageRating", "numVotes"], descending=[True, True])
    .select(["tconst", "primaryTitle", "averageRating", "numVotes"])
    .head(5)
)
print("1. Top 5 filmes com maiores notas:")
print(q1)

  # 2. Qual é o género mais frequente entre os filmes com nota maior que 8?
q2 = (
    basics.filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .filter(pl.col("averageRating") > 8)
    # Separar os géneros (que estão separados por vírgula) numa lista e explodir para múltipl
    .select(pl.col("genres").str.split(",").alias("genre"))
    .explode("genre")
    .drop_nulls(subset=["genre"]) # Remover eventuais nulos
    .group_by("genre")
    .agg(pl.len().alias("frequencia"))
    .sort("frequencia", descending=True)
    .head(1)
```

```
)
print("\n2. Género mais frequente entre filmes com nota > 8:")
print(q2)

 # 3. Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?
q3 = (
    basics.filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .filter(pl.col("averageRating") > 7.5)
    .join(principals, on="tconst", how="inner")
    # Filtrar apenas as categorias 'actor' e 'actress'
    .filter(pl.col("category").is_in(["actor", "actress"]))
    .group_by("nconst") # Agrupar pelo identificador único da pessoa
    .agg(pl.col("tconst").n_unique().alias("numero_de_participacoes"))
    .sort("numero_de_participacoes", descending=True)
    .head(3)
)
print("\n3. Top 3 atores/atrizes em filmes com nota > 7.5:")
print(q3)

from datetime import datetime
from zoneinfo import ZoneInfo

agora = datetime.now(ZoneInfo("America/Sao_Paulo"))
print(agora)
```

```
1. Top 5 filmes com maiores notas:
shape: (5, 4)
| tconst     | primaryTitle             | averageRating | numVotes |
| ---        | ---                      | ---           | ---      |
| str        | str                      | f64           | i64      |
|------------|--------------------------|---------------|----------|
| tt33075815 | Kaveri                   | 10.0          | 1023     |
| tt27815015 | Kurukku                  | 10.0          | 451      |
| tt28450376 | Jedal Dar Omghe 30 Metri | 10.0          | 142      |
| tt27859713 | Sargashte                | 10.0          | 134      |
| tt33507675 | Gorgeous Rascal          | 10.0          | 115      |

2. Género mais frequente entre filmes com nota > 8:
shape: (1, 2)
| genre       | frequencia |
| ---         | ---        |
```

```
| str         | u32        |
|-------------|------------|
| Documentary | 10564      |

3. Top 3 atores/atrizes em filmes com nota > 7.5:
shape: (3, 2)
| nconst    | numero_de_participacoes |
| ---       | ---                     |
| str       | u32                     |
|-----------|-------------------------|
| nm0004660 | 199                     |
| nm0595934 | 155                     |
| nm3183374 | 124                     |
2026-10-14 22:19:00.223959-03:00
```